

Trabajo Práctico N.º 1

Diagnóstico y predicción de niveles de congestión en la red de subtes de la Ciudad Autónoma de Buenos Aires durante el período 2017–2021.



Integrantes:

- * Gisela Martínez
- * Noelia Cualina
- * José Leonardo Carabajal
- * Javier Carabajal

Docentes:

Matías Agustín Pérez · María Cecilia Ribecco · Samira Robador

Resumen

Palabras clave:

Índice

1. Introducción

1.1 Motivaciones

1.2 Descripción del tema

1.3 Objetivos

1.3.1 Objetivo general

1.3.2 Objetivos específicos

1.4 Alcance y limitaciones

1.5 Hipótesis

2. Marco teórico

2.1 Antecedentes

2.2 Movilidad urbana y transporte público

2.3 Demanda de pasajeros en el transporte subterráneo

2.4 Congestión y niveles de demanda

3. Metodología

3.1 Tipo y enfoque del estudio

3.2 Fuentes de datos

3.3 Exploración inicial

3.4 Limpieza y normalización

3.5 Unificación de datasets

3.6 Construcción de variables

3.7 Definición de la variable objetivo

3.8 Desarrollo del modelo

3.9 Evaluación

3.10 Herramientas utilizadas

4. Propuesta de solución

4.1 Análisis exploratorio

4.2 Distribución espacial de la demanda

4.3 Definición de niveles de demanda

4.4 Modelo predictivo

4.5 Evaluación del modelo

4.6 Interpretación de resultados

5. Conclusiones

6. Referencias bibliográficas

7. Anexos

8. Soporte digital

1. Introducción

El crecimiento y la dinámica de las ciudades generan desafíos permanentes para la planificación y gestión de los sistemas de transporte público. En este contexto, los sistemas de transporte ferroviario urbano, como el subterráneo, cumplen un papel relevante debido a su capacidad para movilizar grandes volúmenes de pasajeros y conectar distintos sectores de una ciudad. En este sentido, los sistemas de metro constituyen una infraestructura importante para la movilidad urbana y contribuyen al desarrollo de ciudades sostenibles y resilientes (UITP, 2019).

La demanda de transporte público no se distribuye de manera uniforme, sino que presenta variaciones según factores como el día, el horario, la línea o la estación. Por este motivo, el análisis de los flujos de pasajeros constituye una herramienta útil para comprender el comportamiento de la demanda e identificar períodos o sectores de la red en los que se registran mayores concentraciones de usuarios. **En este sentido, el análisis y la predicción de los flujos de pasajeros pueden contribuir a una mejor comprensión de las fluctuaciones de la demanda y facilitar la planificación de los servicios (UITP, 2022).**

En la Ciudad Autónoma de Buenos Aires, la disponibilidad de registros históricos de viajes realizados en la red de subterráneos permite abordar esta problemática mediante técnicas de análisis de datos. En particular, el conjunto de datos publicado por Buenos Aires Data contiene información sobre la cantidad de pasajeros registrados por molinete y por estación de la red de subterráneos (Gobierno de la Ciudad Autónoma de Buenos Aires, 2021).

A partir de estos datos, el presente trabajo propone realizar un diagnóstico de los patrones de demanda de la red de subterráneos de la Ciudad Autónoma de Buenos Aires durante el período 2017–2021 y evaluar la posibilidad de construir un modelo predictivo capaz de identificar situaciones de alta demanda. Debido a que los registros disponibles no contienen mediciones directas de ocupación o densidad de pasajeros, la cantidad de pasajeros será utilizada como una aproximación a los niveles de congestión.

De esta manera, el trabajo combina un enfoque descriptivo, orientado a caracterizar el comportamiento histórico de la demanda, con un enfoque predictivo basado en técnicas de aprendizaje automático, buscando determinar en qué medida los patrones presentes en los datos permiten anticipar escenarios de elevada demanda.

1.1 Motivaciones

La movilidad urbana constituye un componente fundamental del funcionamiento de las grandes ciudades, debido a que permite conectar personas, actividades económicas, educativas y servicios. En este contexto, el transporte público cumple un papel central, ya que concentra una parte significativa de los desplazamientos cotidianos y su funcionamiento puede verse condicionado por variaciones en la demanda según el día, el horario, la estación y otros factores.

La red de subterráneos de la Ciudad Autónoma de Buenos Aires constituye un sistema de transporte de alta relevancia para la movilidad metropolitana. El análisis de los registros históricos de pasajeros permite estudiar cómo se distribuye la demanda y detectar patrones que pueden resultar útiles para anticipar situaciones de elevada concentración de usuarios.

El presente trabajo surge del interés por aplicar técnicas de análisis de datos y aprendizaje automático a un problema concreto de movilidad urbana. La propuesta busca integrar exploración, preparación de datos y modelado predictivo para transformar registros históricos en información que contribuya a comprender y anticipar niveles elevados de demanda.

1.2 Descripción del tema

Problema de investigación

La red de subterráneos de CABA registra diariamente un volumen importante de pasajeros distribuido entre distintas líneas, estaciones, molinetes y períodos horarios. Esta demanda no es uniforme y puede presentar variaciones asociadas a factores temporales y a las características de cada estación.

El problema de investigación consiste en determinar si, a partir de las variables disponibles en los registros históricos de pasajeros correspondientes al período 2017–2021, es posible identificar patrones de demanda y **construir un modelo que permita estimar la probabilidad de situaciones clasificadas como de alta demanda.**

En este trabajo, el término congestión se utiliza como una aproximación analítica vinculada a niveles elevados de demanda. Los datos disponibles no incluyen mediciones directas de densidad de pasajeros, ocupación de trenes o capacidad instantánea de las estaciones. Por este motivo, el volumen de pasajeros registrado se emplea como indicador o variable proxy para representar situaciones de mayor demanda.

1.3 Objetivos

1.3.1 Objetivo general

Analizar los patrones de demanda de pasajeros de la red de subterráneos de la Ciudad Autónoma de Buenos Aires durante el período 2017–2021 y desarrollar un modelo de aprendizaje automático que permita clasificar y predecir situaciones de alta demanda a partir de las variables disponibles.

1.3.2 Objetivos específicos

1. Analizar la evolución y distribución del volumen de pasajeros por estación, línea y período entre 2017 y 2021.
2. Definir criterios que permitan clasificar los registros de demanda en diferentes niveles de congestión, tales como baja, media y alta.
3. Analizar la relación entre los niveles de congestión y factores temporales y contextuales, como el día de la semana, la estación, la línea, las tarifas y períodos extraordinarios de movilidad.
4. Identificar estaciones, líneas y períodos que presenten una mayor frecuencia de situaciones de alta congestión.
5. Desarrollar un modelo de clasificación que permita estimar la probabilidad de ocurrencia de situaciones de alta congestión a partir de las variables disponibles.
6. Evaluar el desempeño del modelo mediante métricas de clasificación, prestando especial atención a su capacidad para identificar correctamente los casos de alta congestión y controlar la generación de falsas alarmas.
7. Determinar cuáles son las variables que presentan mayor influencia en la predicción de situaciones de alta congestión.

1.4 Alcance y limitaciones

Alcance

El estudio comprende registros de pasajeros de la red de subterráneos de CABA correspondientes al período 2017–2021. El trabajo contempla la exploración y preparación de los datos, su integración en una estructura común, la construcción de variables derivadas, el análisis descriptivo de los patrones de demanda y el desarrollo y evaluación de un modelo de clasificación.

Limitaciones

La principal limitación se relaciona con la naturaleza de los datos disponibles. Las diferencias de estructura entre los archivos anuales requieren tareas de limpieza y normalización antes de su integración, por ejemplo encontramos estructuras con más campos que otros archivos y otros tenían columnas de menos, entre otras cosas.

Los archivos disponibles tienen un peso considerable por el cual no se pueden trabajar de forma directa, por lo que tuvimos que utilizar métodos de transformación de archivos, como por ejemplo pasarlos a .parquet.

Los resultados del modelo estarán condicionados por la calidad, completitud y consistencia de los registros disponibles y por el criterio seleccionado para definir los niveles de demanda.

1.5 Hipótesis

Los episodios de alta congestión en la red de subtes de CABA durante el período 2017–2021 no se distribuyen de manera uniforme entre las estaciones y los días analizados, sino que presentan patrones asociados principalmente a factores temporales y a las características de las estaciones. Se espera que las estaciones con mayor conectividad dentro de la red y los días hábiles presenten una mayor probabilidad de registrar niveles elevados de demanda, permitiendo predecir situaciones de alta congestión a partir de estas características.

2. Marco teórico

El presente marco teórico reúne los conceptos necesarios para comprender el problema de investigación y fundamentar las decisiones metodológicas posteriores. Se abordan antecedentes relacionados con el análisis de movilidad, la demanda de pasajeros y la utilización de técnicas de análisis de datos y aprendizaje automático para estudiar sistemas de transporte.

La revisión conceptual permite establecer una distinción entre congestión física y niveles elevados de demanda. Dado que el conjunto de datos utilizado no contiene mediciones directas de ocupación o densidad, el estudio adopta el volumen de pasajeros como indicador operativo para identificar situaciones de mayor demanda.

2.1 Antecedentes

La predicción de la demanda de pasajeros constituye un área de interés dentro del estudio de los sistemas de transporte público, debido a que permite analizar los patrones de movilidad registrados históricamente y evaluar la posibilidad de anticipar variaciones en los flujos de usuarios.

En este sentido, **Xie et al. (2020)** realizaron una revisión de métodos de predicción de flujos urbanos a partir de datos espacio-temporales. Los autores señalan que estos flujos presentan patrones complejos y dinámicos que pueden estar relacionados con factores como las actividades humanas, los eventos, los días festivos y las condiciones meteorológicas. Asimismo, identifican diferentes enfoques utilizados para su predicción, entre ellos métodos estadísticos, técnicas tradicionales de aprendizaje automático y modelos de aprendizaje profundo.

En el ámbito específico del transporte ferroviario urbano, **Yang et al. (2021)** utilizaron datos históricos provenientes de sistemas automáticos de cobro mediante tarjetas inteligentes para desarrollar un modelo destinado a predecir el volumen de pasajeros a corto plazo en estaciones ferroviarias urbanas. Los autores destacan que estos sistemas permiten disponer de grandes cantidades de registros históricos de viajes, los cuales pueden utilizarse para estudiar el comportamiento del flujo de pasajeros y desarrollar modelos predictivos.

Por otra parte, **Zhou, Wang y Zhao (2020)** estudiaron específicamente la predicción del flujo de pasajeros en una estación de transferencia del metro de Hangzhou, China, utilizando datos provenientes de su sistema automático de cobro. Los autores destacan la relevancia de las estaciones de transferencia dentro de las redes de metro y señalan que estas pueden presentar flujos de pasajeros superiores a los de estaciones regulares, especialmente durante los horarios

de mayor demanda. Para abordar el problema desarrollaron y evaluaron un modelo de predicción de flujo de pasajeros a partir de registros históricos.

Estos antecedentes muestran que los registros históricos generados por los sistemas de transporte pueden utilizarse tanto para estudiar los patrones temporales y espaciales de la demanda como para desarrollar modelos orientados a su predicción. A partir de este marco, el presente trabajo propone aplicar un enfoque similar sobre los registros históricos de la red de subterráneos de CABA, combinando un diagnóstico de los patrones de demanda durante el período 2017–2021 con el desarrollo de un modelo de clasificación orientado a identificar situaciones de alta demanda.

2.2 Movilidad urbana y transporte público

La movilidad urbana comprende los desplazamientos que realizan las personas dentro de un territorio para acceder a actividades laborales, educativas, comerciales, recreativas y a distintos servicios. En este contexto, el transporte público constituye un componente fundamental de los sistemas de movilidad urbana, ya que permite atender grandes volúmenes de desplazamientos y conectar diferentes sectores de las ciudades.

Dentro de los sistemas de transporte público, las redes de metro o subterráneo cumplen un papel relevante debido a su capacidad para transportar grandes cantidades de pasajeros en entornos urbanos de alta densidad. La **International Association of Public Transport (UITP, 2019)** destaca a los sistemas de metro como elementos estructurantes de la movilidad urbana y señala su importancia para el desarrollo de ciudades sostenibles y resilientes.

El funcionamiento de estos sistemas se encuentra estrechamente relacionado con la distribución espacial y temporal de la demanda. Las estaciones no presentan necesariamente los mismos volúmenes de pasajeros y los flujos pueden variar según el momento del día, el día de la semana y las características de cada sector de la red. Estas variaciones permiten estudiar patrones de movilidad a partir de registros históricos de pasajeros.

En el caso de la red de subterráneos de la Ciudad Autónoma de Buenos Aires, el análisis de estos patrones permite caracterizar cómo se distribuye la demanda entre líneas, estaciones y períodos temporales. Esta perspectiva constituye la base para el diagnóstico propuesto en el presente trabajo y para la posterior identificación de situaciones de alta demanda.

2.3 Demanda de pasajeros en el transporte subterráneo

La demanda de pasajeros representa la cantidad de usuarios que utilizan un servicio de transporte durante un período determinado. Su comportamiento puede presentar variaciones temporales y espaciales relacionadas, entre otros factores, con el día de la semana, la franja horaria y las características de las estaciones y líneas. Estas variaciones generan patrones de movilidad que pueden ser estudiados a partir de registros históricos de utilización del sistema.

En este sentido, **Xie et al. (2020)** señalan que los flujos urbanos presentan características espacio-temporales y que su comportamiento puede estar relacionado con distintos factores asociados a la actividad humana y al contexto. En el ámbito específico del transporte ferroviario urbano, **Yang et al. (2021)** utilizaron registros históricos provenientes de sistemas automáticos de cobro para estudiar y predecir el volumen de pasajeros, mostrando la utilidad de este tipo de información para identificar patrones de demanda.

En el presente trabajo se consideran los registros históricos de pasajeros de la red de subterráneos de CABA. Los datos disponibles incluyen pasajeros pagos, pasajeros con pases y pasajeros franquiciados, cuya suma permite obtener una medida del volumen total de pasajeros registrado para cada observación.

Debido a que los datos utilizados no contienen variables que midan directamente la densidad de pasajeros, la ocupación de los trenes o la capacidad instantánea de las estaciones, el volumen de pasajeros registrado será utilizado como medida de demanda. A partir de esta variable se buscará identificar distintos niveles de demanda que permitan posteriormente abordar el diagnóstico y la predicción de situaciones de elevada concentración de pasajeros.

2.4 Congestión y niveles de demanda

La congestión en los sistemas de transporte puede asociarse con situaciones en las que la demanda alcanza o supera determinados niveles de capacidad, generando una elevada concentración de usuarios. Sin embargo, dado que los datos utilizados en este estudio no incluyen mediciones directas de ocupación, densidad de pasajeros o capacidad de las estaciones, la congestión no puede ser medida de forma directa. Por este motivo, se utilizarán los niveles de demanda como una aproximación para identificar situaciones de elevada concentración de pasajeros.

Para este estudio se propone clasificar las observaciones en niveles de demanda **baja, media y alta**, mediante un criterio estadístico definido a partir de la distribución del volumen total de pasajeros. El criterio definitivo se establecerá luego de la exploración de los datos y deberá mantenerse consistente durante el entrenamiento y la evaluación del modelo predictivo.

3. Metodología

La metodología se estructura en etapas sucesivas de adquisición, exploración, limpieza, integración, transformación, análisis y modelado. El objetivo es garantizar que los datos utilizados por el modelo sean consistentes y que las decisiones de preparación puedan ser justificadas y reproducidas.

3.1 Tipo y enfoque del estudio

El presente trabajo adopta un enfoque cuantitativo y combina un alcance descriptivo y predictivo. En una primera etapa se realizará un diagnóstico de los registros históricos de pasajeros con el objetivo de caracterizar la evolución y distribución de la demanda según variables temporales, líneas y estaciones. Posteriormente, se abordará un enfoque predictivo mediante técnicas de aprendizaje automático, con el propósito de desarrollar un modelo de clasificación que permita estimar niveles de demanda a partir de las variables disponibles.

El estudio se basa en datos históricos correspondientes al período 2017–2021 y comprende distintas etapas de exploración, limpieza, normalización, integración y transformación de los datos, seguidas por la construcción y evaluación del modelo predictivo.

Para organizar el desarrollo del proyecto se adoptará como referencia la metodología **CRISP-DM (Cross-Industry Standard Process for Data Mining)**, que estructura los proyectos de análisis y minería de datos en etapas sucesivas: comprensión del negocio o problema, comprensión de los datos, preparación de los datos, modelado, evaluación y despliegue. En el presente trabajo, estas etapas serán adaptadas al contexto académico y al objetivo de diagnosticar y predecir niveles de demanda en la red de subterráneos de CABA.

3.2 Fuentes de datos

Para el desarrollo del estudio se utilizarán conjuntos de datos históricos correspondientes a los viajes registrados en la red de subterráneos de la Ciudad Autónoma de Buenos Aires durante los

años **2017, 2018, 2019, 2020 y 2021**. Los datos fueron obtenidos a partir del portal de datos abiertos **Buenos Aires Data**, publicado por el Gobierno de la Ciudad Autónoma de Buenos Aires, mediante el conjunto de datos *Subte: Viajes Molinetes*.

Los archivos contienen registros asociados al flujo de pasajeros en las distintas líneas, estaciones y molinetes de la red, incluyendo información temporal y cantidades de pasajeros según las categorías disponibles en cada período. Estos registros constituyen la fuente principal para el diagnóstico de la demanda y el posterior desarrollo del modelo predictivo.

Debido a que los archivos correspondientes a los distintos años presentan diferencias en la cantidad, denominación y estructura de sus variables, será necesario realizar una revisión individual, seguida de tareas de limpieza y normalización, antes de integrarlos en un conjunto de datos común.

3.3 Exploración inicial de los datos

Se realizó una exploración inicial de los conjuntos de datos correspondientes al período 2017–2021 con el objetivo de conocer su estructura y evaluar su calidad antes de realizar la integración. Para cada archivo se analizaron la cantidad de registros y variables, los tipos de datos, los valores faltantes, los registros duplicados y las posibles inconsistencias en los formatos y contenidos.

Esta exploración permitió identificar diferencias entre los archivos anuales, principalmente en la denominación y presencia de determinadas variables, así como inconsistencias en algunos campos temporales. A partir de estos resultados se definieron las tareas de limpieza y normalización necesarias para construir posteriormente una estructura común.

3.4 Limpieza y normalización

A partir de los resultados obtenidos durante la exploración inicial, se realizaron tareas de limpieza y normalización orientadas a mejorar la calidad y consistencia de los datos. Este proceso comprendió la identificación y tratamiento de valores faltantes y registros duplicados, así como la revisión de formatos inconsistentes y posibles errores de tipificación.

Asimismo, se normalizaron los nombres de las variables y se revisaron los formatos de fechas, horarios y categorías con el objetivo de establecer una estructura homogénea entre los

diferentes archivos anuales. Estas transformaciones permiten preparar los conjuntos de datos para su posterior integración y análisis.

3.5 Unificación de los conjuntos de datos

A partir de la revisión de los conjuntos de datos correspondientes a los años 2017–2021, se identificaron diferencias en la cantidad, denominación y presencia de determinadas variables. Para facilitar su posterior integración, se normalizaron los nombres de las columnas utilizando una nomenclatura común y se identificaron las variables equivalentes entre los distintos archivos.

Entre las principales diferencias detectadas, el conjunto correspondiente a 2017 contiene las variables adicionales V1 e ID_ESTACION y utiliza la denominación PAX_FREQ, posteriormente homologada con PAX_FRANQ. Por otra parte, los conjuntos de 2018, 2019 y 2021 incluyen la variable PERIODO, mientras que esta no se encuentra presente en el archivo correspondiente a 2020.

A partir de estas diferencias se definirá una estructura común que permita integrar los registros de los cinco años, conservando las variables necesarias para el diagnóstico de la demanda y el posterior desarrollo del modelo predictivo.

Año	Columnas originales	Observaciones	Tratamiento
2017	12	Incluye V1 e ID_ESTACION; utiliza PAX_FREQ	Normalizar nombres y homologar PAX_FREQ con PAX_FRANQ
2018	11	Incluye PERIODO	Normalizar nombres y tipos
2019	11	Incluye PERIODO	Normalizar nombres y tipos
2020	10	No contiene PERIODO	Evaluar su construcción a partir de las variables disponibles
2021	11	Incluye PERIODO	Normalizar nombres y tipos

3.6 Construcción de variables

A partir de las variables originales se construirán variables derivadas que permitan representar características temporales relevantes para el diagnóstico y el modelo predictivo. Entre ellas se

consideran el **año, mes, día de la semana, hora o franja horaria y condición de día hábil**, obtenidas principalmente a partir de las variables de fecha y horario.

Asimismo, se verificará la variable correspondiente al **total de pasajeros** y, cuando sea necesario, se calculará a partir de la suma de los componentes disponibles, como pasajeros pagos, pasajeros con pases y pasajeros franquiciados. La construcción definitiva de las variables derivadas se realizará luego de completar la normalización e integración de los conjuntos anuales.

Variables originales principales:

Variable	Tipo	Descripción
Fecha	Temporal	Fecha correspondiente al registro.
Desde	Temporal	Hora inicial del intervalo registrado.
Hasta	Temporal	Hora final del intervalo registrado.
Línea	Categórica	Línea de subterráneo asociada al registro.
Molinete	Categórica	Identificador o referencia del molinete.
ID_Estacion	Categórica	Identificador de la estación.
PAX_PAGOS	Numérica	Cantidad de <u>pasajeros pagos</u> .
PAX_PASES	Numérica	Cantidad de pasajeros con pases.
PAX_FRANQ	Numérica	Cantidad de pasajeros franquiciados.
TOTAL	Numérica	Volumen total de pasajeros registrado.

Variables derivadas propuestas:

Variable	Tipo	Descripción
AÑO	Temporal	Año correspondiente al registro.
MES	Temporal	Mes correspondiente al registro.
DIA_SEMANA	Categórica	Día de la semana correspondiente a la fecha.
HORA / FRANJA_HORARIA	Temporal/Categórica	Hora o intervalo horario derivado del registro.
DIA_HABIL	Categórica/binaria	Indica si el registro corresponde a un día hábil.

3.7 Definición de niveles de demanda

La variable objetivo será construida a partir del volumen total de pasajeros registrado. Para ello, se analizará la distribución de la variable TOTAL y se establecerá un criterio reproducible que permita clasificar las observaciones en tres categorías: **baja, media y alta demanda**.

El criterio podrá basarse en cuantiles u otros puntos de corte estadísticamente justificados a partir del comportamiento de los datos. La metodología seleccionada y los valores de corte definitivos serán documentados y establecidos antes del entrenamiento del modelo predictivo.

3.8 Desarrollo del modelo predictivo

El problema predictivo será abordado mediante un enfoque de **clasificación supervisada**, utilizando como variable objetivo el nivel de demanda definido previamente. Las variables originales seleccionadas y las variables derivadas serán utilizadas como predictores para estimar la categoría de demanda correspondiente a cada observación.

Se evaluarán modelos adecuados para problemas de clasificación y se seleccionará el enfoque que presente resultados consistentes con los objetivos del estudio y permita una adecuada interpretación de las predicciones.

Los datos serán separados en conjuntos de entrenamiento y prueba, procurando evitar fugas de información (*data leakage*). Las transformaciones o parámetros que deban aprenderse a partir de los datos serán obtenidos utilizando el conjunto de entrenamiento y posteriormente aplicados al conjunto de prueba.

3.9 Evaluación del modelo

El desempeño del modelo será evaluado mediante diferentes métricas de clasificación, incluyendo **exactitud (*accuracy*)**, **precisión (*precisión*)**, **sensibilidad (*recall*)** y **F1-score**, junto con el análisis de la **matriz de confusión**.

Se prestará especial atención al desempeño del modelo sobre los casos correspondientes a **alta demanda**, analizando particularmente los falsos negativos y falsos positivos. Esto permitirá evaluar no solo el desempeño general del modelo, sino también su capacidad para identificar correctamente las situaciones de mayor interés para el objetivo predictivo del estudio.

3.10 Herramientas utilizadas

El procesamiento y análisis de los datos se realizará principalmente mediante Python, utilizando Google Colab como entorno de desarrollo y ejecución del proyecto. Este entorno permite trabajar con los conjuntos de datos y desarrollar de manera integrada las distintas etapas del análisis.

Para la manipulación, transformación y exploración de los datos se utilizarán principalmente las bibliotecas pandas y NumPy. Asimismo, se empleará DuckDB para realizar consultas sobre los conjuntos de datos mediante SQL y facilitar el análisis de grandes volúmenes de registros. Para la generación de gráficos y visualizaciones se utilizará Matplotlib.

En las etapas posteriores se incorporarán las bibliotecas de Python necesarias para el desarrollo y evaluación del modelo de aprendizaje automático, de acuerdo con los algoritmos que se seleccionen.

4. Propuesta de solución

La propuesta integra el análisis exploratorio de los registros históricos con un modelo de clasificación capaz de estimar niveles de demanda. La solución se organizará en una secuencia de procesamiento reproducible.

Datos	EDA	Limpieza	Modelado	Evaluación
-------	-----	----------	----------	------------

Figura 1. Flujo general de la propuesta metodológica.

4.1 Análisis exploratorio

Se analizará la evolución anual del volumen de pasajeros y su distribución: por línea, estación, día de la semana y franja horaria. También se estudiarán valores atípicos y variaciones que puedan afectar la definición de los niveles de demanda.

4.2 Distribución espacial de la demanda

La distribución por estación permitirá identificar concentraciones de demanda y comparar el comportamiento de distintas zonas de la red. Cuando sea posible, se incorporarán visualizaciones por línea y estación para facilitar la interpretación de los resultados.

4.3 Definición de niveles de demanda

Luego del análisis exploratorio se aplicará el criterio estadístico seleccionado para construir la variable objetivo. Se verificará la cantidad y proporción de observaciones pertenecientes a cada categoría para evitar clases excesivamente desbalanceadas.

4.4 Modelo predictivo

El modelo tendrá como variable objetivo el nivel de demanda. Como variables explicativas se considerarán las características temporales y de infraestructura disponibles, junto con las transformaciones justificadas durante el análisis. Se documentarán los parámetros principales y las decisiones adoptadas.

4.5 Evaluación del modelo

Los resultados se presentarán mediante una matriz de confusión y métricas de clasificación. Se analizarán especialmente los falsos negativos y falsos positivos asociados a la categoría de alta demanda.

4.6 Interpretación de resultados

Además de medir el desempeño predictivo, se analizará qué variables contribuyen en mayor medida a la clasificación. Esta interpretación permitirá relacionar los resultados del modelo con los patrones observados durante el análisis exploratorio.

Figura 2. Evolución del volumen de pasajeros por año. (Incorporar gráfico generado en el notebook.)

Figura 3. Distribución de pasajeros por línea. (Incorporar gráfico generado en el notebook.)

Figura 4. Distribución de pasajeros por día de la semana. (Incorporar gráfico generado en el notebook.)

Figura 5. Distribución de los niveles de demanda. (Incorporar gráfico generado en el notebook.)

Figura 6. Matriz de confusión del modelo final. (Incorporar resultado final.)

Figura 7. Importancia de variables o explicación del modelo. (Incorporar resultado final.)

5. Conclusiones

Esta sección se completará una vez finalizados el análisis exploratorio y el modelado. Las conclusiones deberán responder de manera explícita a los objetivos planteados y a la hipótesis, evitando incorporar información que no haya sido analizada en el desarrollo.

- Resultado correspondiente al objetivo: Analizar la evolución y distribución de pasajeros por estación, línea y período durante 2017–2021.
- Resultado correspondiente al objetivo: Definir criterios para clasificar los registros en niveles de demanda baja, media y alta.
- Resultado correspondiente al objetivo: Analizar la relación entre los niveles de demanda y factores temporales y contextuales, como día de la semana, estación, línea, período y condiciones extraordinarias.
- Resultado correspondiente al objetivo: Identificar las estaciones, líneas y períodos en los que se presentan con mayor frecuencia situaciones de alta demanda.
- Resultado correspondiente al objetivo: Desarrollar un modelo de clasificación que permita estimar la probabilidad de situaciones de alta demanda a partir de las variables disponibles.
- Resultado correspondiente al objetivo: Evaluar el desempeño del modelo mediante métricas de clasificación, prestando especial atención a la identificación correcta de los casos de alta demanda y al control de falsas alarmas.
- Resultado correspondiente al objetivo: Determinar cuáles son las variables que presentan mayor influencia en la predicción de los niveles de demanda.

Finalmente, se incorporarán las principales conclusiones metodológicas, las limitaciones observadas y posibles líneas de trabajo futuro.

6. Referencias bibliográficas

International Association of Public Transport. (2019). *Metros: The backbone of mobile communities and sustainable cities*. UITP.

[UITP — Metros: The Backbone of Mobile Communities and Sustainable Cities](#)

International Association of Public Transport. (2022). *Improving passenger flow and crowd management through technology and innovation*. UITP.

[UITP — Improving Passenger Flow and Crowd Management Through Technology and Innovation](#)

Gobierno de la Ciudad Autónoma de Buenos Aires. (2021). *Subte: Viajes Molinetes*. Buenos Aires Data.

[Buenos Aires Data — datasets de Subte y movilidad](#)

Xie, P., Li, T., Liu, J., Du, S., Yang, X., & Zhang, J. (2020). *Urban flow prediction from spatiotemporal data using machine learning: A survey*. *Information Fusion*, 59, 1–12.

[Urban flow prediction from spatiotemporal data using machine learning: A survey](#)

Yang, X., Xue, Q., Ding, M., Wu, J., & Gao, Z. (2021). *Short-term prediction of passenger volume for urban rail systems: A deep learning approach based on smart-card data*. *International Journal of Production Economics*, 231, 107920.

[Short-term prediction of passenger volume for urban rail systems: A deep learning approach based on smart-card data](#)

Zhou, W., Wang, W., & Zhao, D. (2020). *Passenger flow forecasting in metro transfer station based on the combination of singular spectrum analysis and AdaBoost-weighted extreme learning machine*. *Sensors*, 20(12), 3555.

[Passenger Flow Forecasting in Metro Transfer Station Based on the Combination of Singular Spectrum Analysis and AdaBoost-Weighted Extreme Learning Machine](#)

Chapman, P., Clinton, J., Kerber, R., Khabaza, T., Reinartz, T., Shearer, C., & Wirth, R. (2000). *CRISP-DM 1.0: Step-by-step data mining guide*. SPSS.

[CRISP-DM 1.0 — Step-by-step data mining guide \(PDF\)](#)